


Modelos Auto Regresivos

Jan Polanco Velasco

Modelos Auto Regresivos

- Regresión Lineal
- Función de costo
- Gradiente descendente
- Regresión Lineal multivariada
- Regresión Logística




Modelos Auto Regresivos

Regresión Lineal

- **Relación lineal:** Este modelo describe una relación lineal entre las entradas x y las salidas y .
- Donde w_0 y w_1 (*weights*) representan el intercepto y la pendiente de la recta, respectivamente.

$$y = w_0 + w_1 \cdot x$$




Modelos Auto Regresivos

Regresión Lineal

- Los pesos pueden tomar cualquier valor.
- Diferentes pesos producen diferentes rectas.
- Es necesario calcular la función de costo (*para encontrar los mejores pesos*).

$$y = w_0 + w_1 \cdot x$$




Modelos Auto Regresivos

Función de costos

- Los pesos pueden tomar cualquier valor.
- Diferentes pesos producen diferentes rectas.
- Es necesario calcular la función de costo (*Los mejores pesos*).
- **La función de costo (asumiendo w_0 conocido):**

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$



10 Most Common Loss Functions in Machine Learning

Regression Loss Functions

Loss Function	Description	Formula
Mean Bias Error (MBE)	Captures average bias in prediction. Rarely used for training.	$\mathcal{L}_{MBE} = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))$
Mean Absolute Error (MAE / L1)	Measures absolute average bias in prediction.	$\mathcal{L}_{MAE} = \frac{1}{N} \sum_{i=1}^N y_i - f(x_i) $
Mean Squared Error (MSE / L2)	Average squared distance between actual and predicted.	$\mathcal{L}_{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2$
Root Mean Squared Error (RMSE)	Square root of MSE. Same units as target.	$\mathcal{L}_{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2}$

10 Most Common Loss Functions in Machine Learning

Regression Loss Functions

Loss Function	Description	Formula
Huber Loss	Combination of MSE and MAE. Parametric robust loss.	$\mathcal{L}_\delta = \begin{cases} \frac{1}{2}(y - f(x))^2 & \text{si } y - f(x) \leq \delta \\ \delta(y - f(x) - \frac{1}{2}\delta) & \text{en otro caso} \end{cases}$
Log Cosh Loss	Similar to Huber, non-parametric, twice differentiable.	$\mathcal{L}_{\log \cosh} = \sum_{i=1}^N \log(\cosh(f(x_i) - y_i))$

10 Most Common Loss Functions in Machine Learning

Classification Loss Functions

Loss Function	Description	Formula
Binary Cross Entropy (BCE)	Loss function for binary classification tasks.	$\mathcal{L}_{BCE} = -\frac{1}{N} \sum [y_i \log p(x_i) + (1 - y_i) \log(1 - p(x_i))]$
Hinge Loss	Penalizes wrong and low-confidence predictions (SVMs).	$\mathcal{L}_{\text{hinge}} = \max(0, 1 - f(x) \cdot y)$
Categorical Cross Entropy	Multi-class classification extension of BCE.	$\mathcal{L}_{CE} = -\frac{1}{N} \sum \sum y_{ij} \log(f(x_{ij}))$
KL Divergence	Relative entropy between true and predicted distributions.	$\mathcal{L}_{KL} = \sum y_i \cdot \log \left(\frac{y_i}{f(x_i)} \right)$


Modelos Auto Regresivos

Gradiente Descendente

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$w^{(t+1)} = w^{(t)} - \alpha \nabla f_i(w^{(t)})$$

- $w^{(t+1)}$: Posición de la siguiente iteración
- $w^{(t)}$: Posición del paso anterior
- α : Tasa de aprendizaje (*learning rate / step size*)
- $\nabla f_i(w^{(t)})$: Gradiente en la observación i




Modelos Auto Regresivos

Gradiente Descendente

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$w^{(t+1)} = w^{(t)} - \alpha \nabla f_i(w^{(t)})$$




Modelos Auto Regresivos

Gradiente Descendente

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$w^{(t+1)} = w^{(t)} - \alpha \nabla f_i(w^{(t)})$$




Modelos Auto Regresivos

Gradiente Descendente

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$w^{(t+1)} = w^{(t)} - \alpha \nabla f_i(w^{(t)})$$




Modelos Auto Regresivos

Regresión Lineal Multivariada

- Se puede aplicar a datos con **múltiples atributos**.
- Los parámetros del modelo se estiman a partir de los conceptos de **Función de costo** y **Gradiente descendente**.

$$\hat{y} = w_0 + \sum_{j=1}^m w_j \cdot x_j$$




Modelos Auto Regresivos

Regresión Lineal Multivariada

- En este caso, la predicción se calcula como una **combinación lineal** de todos los atributos de entrada.

$$\hat{y} = w_0 + \sum_{j=1}^m w_j \cdot x_j$$



Modelos Auto Regresivos


Regresión Logística

- Realiza predicciones a partir de una combinación lineal.
- Se mide la probabilidad de que una instancia pertenezca a una de las dos clases (**clasificación binaria**).

$$\hat{y} = p(y = 1 \mid \mathbf{x}) = \sigma \left(w_0 + \sum_{j=1}^m w_j x_j \right)$$

Donde:

- $\hat{y}$ es la probabilidad de que $y = 1$ dado el vector de atributos $\mathbf{x}$.
- $\sigma(\cdot)$ es la función sigmoide.



Modelos Auto Regresivos


Regresión Logística

- La combinación lineal toma cualquier valor real.
- Para mapear la predicción a una **probabilidad**, se usa la **función sigmoidal**.

$$\hat{y} = p(y = 1 \mid \mathbf{x}) = \sigma \left(w_0 + \sum_{j=1}^m w_j x_j \right)$$

Donde:

- $\hat{y}$ es la probabilidad de que $y = 1$ dado el vector de atributos $\mathbf{x}$.
- $\sigma(\cdot)$ es la función sigmoide.



Modelos Auto Regresivos

Red Neuronal Fully Connected

- **Capa de Entrada** (*Input Layer*)
- **Capa oculta** (*Hidden Layer - h*)
- **Capa de salida** (*Output Layer*)

¿Cuántas capas tiene la NN?

(Modelo biológico de la neurona: dendritas, soma/núcleo, axón vs modelo artificial de suma ponderada + activación)

Modelos Auto Regresivos

Red Neuronal Fully Connected

- La capa de entrada **no suele considerarse** en el conteo de capas.
- **Tiene 4 capas:** $L = 4$ (3 capas ocultas + 1 capa de salida).


Modelos Auto Regresivos

- El **superíndice** indica la capa.
- h_1 necesita $3 + 1$ parámetros.
- La primera capa oculta necesita 4×5 parámetros.

Ecuación general para h_1 :

$$h_1 = g \left(w_{1,0}^{[1]} + \sum_{j=1}^3 w_{1,j}^{[1]} x_j \right)$$

- $g(\cdot)$: Función de activación (ReLU, sigmoide, etc.)
- $w_{1,0}^{[1]}$: Bias o término de sesgo.
- $w_{1,j}^{[1]}$: Peso asociado a cada entrada x_j .



Modelos Auto Regresivos


Red con una capa oculta y salida escalar

Modelos Auto Regresivos

Cálculo de la neurona de salida $\hat{y}$

$$\hat{y} = g \left(w_{1,0}^{[2]} + \sum_{j=1}^3 w_{1,j}^{[2]} h_j \right)$$

- Ponderación de los estados ocultos h_1, h_2, h_3 junto al sesgo $w_{1,0}^{[2]}$.



Modelos Auto Regresivos

Funciones de Activación

- **Añaden No Linealidad:** Las funciones de activación son esenciales para agregar un componente no lineal en las redes neuronales, permitiendo que estas redes puedan aprender y modelar relaciones complejas en los datos.
- **Modelo Lineal sin Activación:** Sin funciones de activación, una red neuronal se reduce a un simple modelo lineal, sin importar cuántas capas ocultas contenga.
- **En Cualquier Capa:** Las funciones de activación pueden colocarse en cualquier capa de la red.

Modelos Auto Regresivos

Funciones de Activación

- Ciertas funciones son más apropiadas para **capas de salida**.
- Otras son mejores para **capas ocultas**, optimizando el rendimiento de la red.

Definición Matemática


Para una unidad en una capa oculta o de salida, el cálculo del valor se realiza mediante la función de activación $g(\cdot)$:

$$h_2 = g \left(w_{2,0}^{[1]} + \sum_{j=1}^4 w_{2,j}^{[1]} x_j \right)$$

Modelos Auto Regresivos

Tipos de Funciones de Activación: Identidad


- **Función Identidad:** $f(x) = x$
- Salida igual a la entrada.
- Recomendación de la diapo anterior: en capas ocultas produce un modelo puramente lineal (no tiene sentido).
- **Se puede usar para regresión** en la capa de salida.



Modelos Auto Regresivos

Tipos de Funciones de Activación: Sigmoides

- **Función sigmoide:** $\sigma(x) = \frac{1}{1+e^{-x}}$
- Rango de valores: $[0, 1]$.
- Se usaba al inicio de las NN, pero introduce problemas de saturación/latencia de gradientes.
- **Softmax** es la versión generalizada para clasificación multiclase en la capa de salida.




Modelos Auto Regresivos

Tipos de Funciones de Activación:

Tangente Hiperbólica

- **Función Tangente Hiperbólica:** $\tanh(x)$
- Rango de valores: $[-1, 1]$.
- Centrada en cero (normaliza los valores respecto a la entrada).
- Puede tener problemas de **gradientes que se desvanecen** (*vanishing gradient problem*) en valores extremos.



Modelos Auto Regresivos


Tipos de Funciones de Activación:

ReLU

- **Función ReLU** (*Rectified Linear Unit*):

$$f(x) = \max(0, x)$$

- Es computacionalmente eficiente y muy usada.
- Se suele usar en **capas ocultas**.
- ¿Hay otros tipos de funciones de activación?



Subconjunto de Funciones de Activación

Función	Fórmula	Función	Fórmula
ReLU	$\max(0, x)$	GELU	$\frac{x}{2} \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (x + 0.044715x^3) \right) \right)$
PReLU	$\max(0, x) + \alpha \min(0, x)$	ELU	$\begin{cases} x & x > 0 \\ \alpha(e^x - 1) & x \leq 0 \end{cases}$
Swish	$\frac{x}{1+e^{-x}}$	SELU	$\lambda \begin{cases} x & x > 0 \\ \alpha(e^x - 1) & x \leq 0 \end{cases}$
SoftPlus	$\frac{1}{\beta} \log(1 + \exp(\beta x))$	Mish	$x \cdot \tanh(\text{softplus}(x))$
Sigmoid	$\frac{1}{1+e^{-x}}$	SoftSign	$\frac{x}{1+ x }$

Modelos Auto Regresivos

Estimación de Hiperparámetros

- **Parámetros:** Son los pesos w y sesgos calculados por optimización.
- **Hiperparámetros:** Son los valores configurados externamente que afectan el aprendizaje de los parámetros.
 - Cantidad de capas.
 - Learning Rate (tamaño del paso en Gradient Descent).
- Ser cuidadosos con la elección de la **función de costo**.

Modelos Auto Regresivos

Selección de Funciones y Optimizadores

- **En regresión:** Se suele usar **RMSE** o **MSE**.
- **En clasificación binaria:** Se suele usar **entropía cruzada binaria (BCE)**.
- **En multiclase:** **Entropía cruzada categórica (CCE)**.
- **Solvers / Optimizadores:** Gradient Descent (GD), ADAM, RMSprop, etc.

Modelos Auto Regresivos

Hiperparámetros de Arquitectura

- L : Cantidad de capas o profundidad de la red.
- **Número de unidades por capa:** La entrada y salida dependen directamente de la definición del problema.
- **Estructura fija:** Rectangular (mismo número de unidades por capa oculta).
- **Estructura variable:** Piramidal (reducción progresiva de neuronas por capa).

Modelos Auto Regresivos

Hiperparámetros de Entrenamiento

- **Learning Rate (LR)**
 - **Funciones de activación**
 - **Batch size y Epochs**
 - **Procesos de regularización** (Dropout, Weight Decay)
 - Estrategias de prueba: *Trial and Error*
 - **Partición de datos:**
 - 60% / 20% / 20% (pocos datos)
 - 90% / 5% / 5% (grandes volúmenes)
 - **Técnicas de búsqueda:**
 - Grid Search
 - Random Search
 - Bayesian Search
- **Grid Search:** Búsqueda exhaustiva en malla regular.
 - **Random Search:** Muestreo aleatorio en el espacio continuo.
 - **Bayesian Search:** Optimización probabilística guiada por evaluaciones previas.

Modelos Auto Regresivos



Juguemos un rato con una NN

(Demostración práctica interactiva / TensorFlow Playground)

Modelos Auto Regresivos

Datos Secuenciales

- ¿Qué son los datos secuenciales?

(Ejemplo: series financieras, índice bursátil Dow Jones a lo largo del tiempo)

Modelos Auto Regresivos

Datos Secuenciales

- ¿Qué son los datos secuenciales?
- **El dato actual depende de la información anterior.**
- **Dependencia temporal.**

Modelos Auto Regresivos

Ejemplos de Datos Secuenciales

- **Series de tiempo**
- **Señales de sensores**
- **La voz (audio)**
- **Secuencia de genes** (*gene sequences*)
- **Información climática**

Modelos Auto Regresivos

Limitaciones de las NN Tradicionales

- Una NN tradicional **asume que los datos no son secuenciales** y que cada punto de datos es independiente de otros puntos de datos (*i.i.d.*).
- **Ejemplo:** Temperatura - Humedad.
- **Carecen de memoria.**
- **Sufren de gradientes que se desvanecen** (*vanishing gradients*) con secuencias largas.

