

Diagnóstico, Regularización y Espectrogramas

Diagnóstico, Regularización y Espectrogramas

De la señal unidimensional al procesamiento convolucional 2D

Diagnóstico, Regularización y Espectrogramas

De la señal unidimensional al procesamiento convolucional 2D

Jan Polanco Velasco

Hoja de Ruta de la Sesión

Hoja de Ruta de la Sesión

Cuatro actos que conectan el entrenamiento con la visión convolucional

Hoja de Ruta de la Sesión

Cuatro actos que conectan el entrenamiento con la visión convolucional

01

Diagnóstico Clínico

Curvas de pérdida, overfitting, underfitting y patologías del gradiente.

Hoja de Ruta de la Sesión

Cuatro actos que conectan el entrenamiento con la visión convolucional

01

Diagnóstico Clínico

Curvas de pérdida, overfitting, underfitting y patologías del gradiente.

02

Estabilización y Regularización

Early Stopping, Dropout y Gradient Clipping.

Hoja de Ruta de la Sesión

Cuatro actos que conectan el entrenamiento con la visión convolucional

01

Diagnóstico Clínico

Curvas de pérdida, overfitting, underfitting y patologías del gradiente.

02

Estabilización y Regularización

Early Stopping, Dropout y Gradient Clipping.

03

De Señales 1D a Imágenes 2D

Audio crudo, STFT y espectrogramas como imágenes.

Hoja de Ruta de la Sesión

Cuatro actos que conectan el entrenamiento con la visión convolucional

01

Diagnóstico Clínico

Curvas de pérdida, overfitting, underfitting y patologías del gradiente.

02

Estabilización y Regularización

Early Stopping, Dropout y Gradient Clipping.

03

De Señales 1D a Imágenes 2D

Audio crudo, STFT y espectrogramas como imágenes.

04

Convolución y Pooling

Downscaling, invarianza y Max vs. Average Pooling.

01

01

Diagnóstico Clínico del Entrenamiento

01

Diagnóstico Clínico del Entrenamiento

Curvas de pérdida, overfitting, underfitting y patologías del gradiente

Diagnóstico de Modelos

Diagnóstico de Modelos

Interpretando las Curvas de
Aprendizaje

Diagnóstico de Modelos

Interpretando las Curvas de Aprendizaje

- **La ventana a la mente de la red:** las curvas de pérdida (*Loss vs. Epochs*) son la herramienta clínica fundamental para diagnosticar el entrenamiento.

Diagnóstico de Modelos

Interpretando las Curvas de Aprendizaje

- **La ventana a la mente de la red:** las curvas de pérdida (*Loss vs. Epochs*) son la herramienta clínica fundamental para diagnosticar el entrenamiento.
- **Generalization Gap:** la brecha entre la pérdida de entrenamiento ($\mathcal{L}_{\text{train}}$) y la de validación ($\mathcal{L}_{\text{val}}$).

Diagnóstico de Modelos

Interpretando las Curvas de Aprendizaje

- **La ventana a la mente de la red:** las curvas de pérdida (*Loss vs. Epochs*) son la herramienta clínica fundamental para diagnosticar el entrenamiento.
- **Generalization Gap:** la brecha entre la pérdida de entrenamiento ($\mathcal{L}_{\text{train}}$) y la de validación ($\mathcal{L}_{\text{val}}$).
- **Sobreajuste (*Overfitting*):** $\mathcal{L}_{\text{train}} \rightarrow 0$ mientras $\mathcal{L}_{\text{val}}$ repunta; la red memoriza el ruido.

Diagnóstico de Modelos

Interpretando las Curvas de Aprendizaje

- **La ventana a la mente de la red:** las curvas de pérdida (*Loss vs. Epochs*) son la herramienta clínica fundamental para diagnosticar el entrenamiento.
- **Generalization Gap:** la brecha entre la pérdida de entrenamiento ($\mathcal{L}_{\text{train}}$) y la de validación ($\mathcal{L}_{\text{val}}$).
- **Sobreajuste (*Overfitting*):** $\mathcal{L}_{\text{train}} \rightarrow 0$ mientras $\mathcal{L}_{\text{val}}$ repunta; la red memoriza el ruido.
- **Subajuste (*Underfitting*):** ambas curvas se estancan en valores altos; falta de capacidad o hipótesis muy rígida.

Diagnóstico de Modelos

Interpretando las Curvas de Aprendizaje

- **La ventana a la mente de la red:** las curvas de pérdida (*Loss vs. Epochs*) son la herramienta clínica fundamental para diagnosticar el entrenamiento.
- **Generalization Gap:** la brecha entre la pérdida de entrenamiento ($\mathcal{L}_{\text{train}}$) y la de validación ($\mathcal{L}_{\text{val}}$).
- **Sobreajuste (Overfitting):** $\mathcal{L}_{\text{train}} \rightarrow 0$ mientras $\mathcal{L}_{\text{val}}$ repunta; la red memoriza el ruido.
- **Subajuste (Underfitting):** ambas curvas se estancan en valores altos; falta de capacidad o hipótesis muy rígida.


1. Overfitting

2. Underfitting

3. Good Fit

4. Explotan

5. Se desvanecen



Perfil de $\|\nabla W\|$ por capa (entrada $\rightarrow$ salida)

norma moderada

L1

L2

L3

L4

Sobreajuste (Alta Varianza)

MÁS COMÚN

La pérdida de entrenamiento sigue bajando (memorización) mientras la de validación se estanca y repunta: surge el generalization gap.

Receta: Dropout (0.2-0.5), Early Stopping, Data Augmentation o reducir parámetros.

Patologías del Gradiente

Patologías del Gradiente

Desvanecimiento vs. Explosión

Patologías del Gradiente

Desvanecimiento vs. Explosión

- **Gradientes que se desvanecen (*Vanishing*):** a través de capas profundas $\|\nabla W\| \rightarrow 0$. Las primeras capas dejan de aprender y se *congelan*.

Patologías del Gradiente

Desvanecimiento vs. Explosión

- **Gradientes que se desvanecen (*Vanishing*):** a través de capas profundas $\|\nabla W\| \rightarrow 0$. Las primeras capas dejan de aprender y se *congelan*.
- **Gradientes que explotan (*Exploding*):** $\|\nabla W\| \rightarrow \infty$, provocando oscilaciones violentas o valores NaN .

Patologías del Gradiente

Desvanecimiento vs. Explosión

- **Gradientes que se desvanecen (*Vanishing*):** a través de capas profundas $\|\nabla W\| \rightarrow 0$. Las primeras capas dejan de aprender y se *congelan*.
- **Gradientes que explotan (*Exploding*):** $\|\nabla W\| \rightarrow \infty$, provocando oscilaciones violentas o valores NaN .
- **Causa raíz:** el producto encadenado de Jacobianos al retropropagar por muchas capas.

Patologías del Gradiente

Desvanecimiento vs. Explosión

- **Gradientes que se desvanecen (*Vanishing*):** a través de capas profundas $\|\nabla W\| \rightarrow 0$. Las primeras capas dejan de aprender y se *congelan*.
- **Gradientes que explotan (*Exploding*):** $\|\nabla W\| \rightarrow \infty$, provocando oscilaciones violentas o valores NaN .
- **Causa raíz:** el producto encadenado de Jacobianos al retropropagar por muchas capas.

Gradient Clipping (recorte por norma):

Patologías del Gradiente

Desvanecimiento vs. Explosión

- **Gradientes que se desvanecen (*Vanishing*):** a través de capas profundas $\|\nabla W\| \rightarrow 0$. Las primeras capas dejan de aprender y se *congelan*.
- **Gradientes que explotan (*Exploding*):** $\|\nabla W\| \rightarrow \infty$, provocando oscilaciones violentas o valores NaN .
- **Causa raíz:** el producto encadenado de Jacobianos al retropropagar por muchas capas.

Gradient Clipping (recorte por norma):

$$g \leftarrow \begin{cases} g & \text{si } \|g\| \leq c \\ c \cdot \frac{g}{\|g\|} & \text{si } \|g\| > c \end{cases}$$

Patologías del Gradiente

Desvanecimiento vs. Explosión

- **Gradientes que se desvanecen (*Vanishing*):** a través de capas profundas $\|\nabla W\| \rightarrow 0$. Las primeras capas dejan de aprender y se *congelan*.
- **Gradientes que explotan (*Exploding*):** $\|\nabla W\| \rightarrow \infty$, provocando oscilaciones violentas o valores NaN .
- **Causa raíz:** el producto encadenado de Jacobianos al retropropagar por muchas capas.

Gradient Clipping (recorte por norma):

$$g \leftarrow \begin{cases} g & \text{si } \|g\| \leq c \\ c \cdot \frac{g}{\|g\|} & \text{si } \|g\| > c \end{cases}$$

Gradient Clipping en Keras

```
optimizer = tf.keras.optimizers.Adam(  
    learning_rate=0.001,  
    clipnorm=1.0  
)
```

Si la norma del gradiente supera el umbral c , se reescala conservando su dirección. Evita que un lote corrupto destruya los pesos de la red.

02

02

Arsenal de Estabilización y Regularización

02

Arsenal de Estabilización y Regularización

Early Stopping, Dropout y Gradient Clipping

Early Stopping (Detención Temprana)

Early Stopping (Detención Temprana)

Detener a tiempo es una forma de regularizar

Early Stopping (Detención Temprana)

Detener a tiempo es una forma de regularizar

- Monitorea una métrica de validación (típicamente `val_loss`) tras cada época.

Early Stopping (Detención Temprana)

Detener a tiempo es una forma de regularizar

- Monitorea una métrica de validación (típicamente `val_loss`) tras cada época.
- Si no mejora durante un número de épocas de gracia (*patience*), detiene el entrenamiento.

Early Stopping (Detención Temprana)

Detener a tiempo es una forma de regularizar

- Monitorea una métrica de validación (típicamente `val_loss`) tras cada época.
- Si no mejora durante un número de épocas de gracia (*patience*), detiene el entrenamiento.
- Con `restore_best_weights=True` recupera los pesos de la **mejor época**, no los últimos.

Early Stopping (Detención Temprana)

Detener a tiempo es una forma de regularizar

- Monitorea una métrica de validación (típicamente `val_loss`) tras cada época.
- Si no mejora durante un número de épocas de gracia (*patience*), detiene el entrenamiento.
- Con `restore_best_weights=True` recupera los pesos de la **mejor época**, no los últimos.
- **No es solo diagnóstico:** es una técnica de regularización que evita que el modelo entre en la zona de sobreajuste.

Early Stopping (Detención Temprana)

Detener a tiempo es una forma de regularizar

- Monitorea una métrica de validación (típicamente `val_loss`) tras cada época.
- Si no mejora durante un número de épocas de gracia (*patience*), detiene el entrenamiento.
- Con `restore_best_weights=True` recupera los pesos de la **mejor época**, no los últimos.
- **No es solo diagnóstico:** es una técnica de regularización que evita que el modelo entre en la zona de sobreajuste.

Callback en Keras

```
es = tf.keras.callbacks.EarlyStopping(  
    monitor='val_loss',  
    patience=8,  
    restore_best_weights=True  
)  
  
model.fit( ... , callbacks=[es])
```

La *paciencia* deja margen a que la pérdida vuelva a bajar antes de rendirse.

Dropout

Dropout

Apagar neuronas para forzar representaciones robustas

Dropout

Apagar neuronas para forzar representaciones robustas

- En cada paso de entrenamiento, cada neurona se "apaga" con probabilidad p (p. ej. $p = 0.3$).

Dropout

Apagar neuronas para forzar representaciones robustas

- En cada paso de entrenamiento, cada neurona se "apaga" con probabilidad p (p. ej. $p = 0.3$).
- **Efecto:** rompe co-adaptaciones; la red no puede depender de una sola neurona.

Dropout

Apagar neuronas para forzar representaciones robustas

- En cada paso de entrenamiento, cada neurona se "apaga" con probabilidad p (p. ej. $p = 0.3$).
- **Efecto:** rompe co-adaptaciones; la red no puede depender de una sola neurona.
- **Dropout invertido:** en inferencia no se apaga nada; las activaciones se escalan por $(1 - p)$ durante el entrenamiento para mantener la misma esperanza.

Dropout

Apagar neuronas para forzar representaciones robustas


- En cada paso de entrenamiento, cada neurona se "apaga" con probabilidad p (p. ej. $p = 0.3$).
- **Efecto:** rompe co-adaptaciones; la red no puede depender de una sola neurona.
- **Dropout invertido:** en inferencia no se apaga nada; las activaciones se escalan por $(1 - p)$ durante el entrenamiento para mantener la misma esperanza.
- Equivale a entrenar un **ensamble implícito** de 2^N sub-redes que comparten pesos.

Dropout

Apagar neuronas para forzar representaciones robustas

- En cada paso de entrenamiento, cada neurona se "apaga" con probabilidad p (p. ej. $p = 0.3$).
- **Efecto:** rompe co-adaptaciones; la red no puede depender de una sola neurona.
- **Dropout invertido:** en inferencia no se apaga nada; las activaciones se escalan por $(1 - p)$ durante el entrenamiento para mantener la misma esperanza.
- Equivale a entrenar un **ensamble implícito** de 2^N sub-redes que comparten pesos.

Dropout ($p = 0.3$) – apagado aleatorio



Las neuronas en rojo se desactivan en esta iteración.

El Botiquín Completo de Regularización

El Botiquín Completo de Regularización

Batch Normalization

Normaliza las activaciones por lote. Acelera la convergencia y reduce la sensibilidad a la inicialización.

El Botiquín Completo de Regularización

Batch Normalization

Normaliza las activaciones por lote. Acelera la convergencia y reduce la sensibilidad a la inicialización.

Weight Decay (L2)

Penaliza pesos grandes con penalización L2 sobre los pesos ($\lambda \cdot \sum w^2$).
Mantiene la función suave y evita el sobreajuste.

El Botiquín Completo de Regularización

Batch Normalization

Normaliza las activaciones por lote. Acelera la convergencia y reduce la sensibilidad a la inicialización.

Weight Decay (L2)

Penaliza pesos grandes con penalización L2 sobre los pesos ($\lambda \cdot \sum w^2$).
Mantiene la función suave y evita el sobreajuste.

Data Augmentation

Genera variaciones realistas (ruido, desplazamientos temporales) para ampliar el conjunto de entrenamiento.

El Botiquín Completo de Regularización

Batch Normalization

Normaliza las activaciones por lote. Acelera la convergencia y reduce la sensibilidad a la inicialización.

Weight Decay (L2)

Penaliza pesos grandes con penalización L2 sobre los pesos ($\lambda \cdot \sum w^2$).
Mantiene la función suave y evita el sobreajuste.

Data Augmentation

Genera variaciones realistas (ruido, desplazamientos temporales) para ampliar el conjunto de entrenamiento.

Inicialización Adecuada

He/Glorot mantienen la varianza del gradiente estable entre capas, combatiendo el desvanecimiento.

03

03

De Señales 1D a Imágenes 2D

03

De Señales 1D a Imágenes 2D

Audio crudo, STFT y espectrogramas

Procesamiento de Audio: la Señal 1D

Procesamiento de Audio: la Señal 1D

¿Por qué el audio crudo es difícil para una red?

Procesamiento de Audio: la Señal 1D

¿Por qué el audio crudo es difícil para una red?

- **Forma de onda:** presión sonora en el tiempo $x(t)$.

Procesamiento de Audio: la Señal 1D

¿Por qué el audio crudo es difícil para una red?

- **Forma de onda:** presión sonora en el tiempo $x(t)$.
- **Muestreo:** a 16 kHz, 1 segundo = **16.000 muestras**.

Procesamiento de Audio: la Señal 1D

¿Por qué el audio crudo es difícil para una red?

- **Forma de onda:** presión sonora en el tiempo $x(t)$.
- **Muestreo:** a 16 kHz, 1 segundo = **16.000 muestras**.
- **Desafíos:** dimensionalidad colosal y sensibilidad extrema al desfase.

Procesamiento de Audio: la Señal 1D

¿Por qué el audio crudo es difícil para una red?

- **Forma de onda:** presión sonora en el tiempo $x(t)$.
- **Muestreo:** a 16 kHz, 1 segundo = **16.000 muestras**.
- **Desafíos:** dimensionalidad colosal y sensibilidad extrema al desfase.
- **Solución clásica:** pasar al **dominio de la frecuencia**.

Procesamiento de Audio: la Señal 1D

¿Por qué el audio crudo es difícil para una red?

- **Forma de onda:** presión sonora en el tiempo $x(t)$.
- **Muestreo:** a 16 kHz, 1 segundo = **16.000 muestras**.
- **Desafíos:** dimensionalidad colosal y sensibilidad extrema al desfase.
- **Solución clásica:** pasar al **dominio de la frecuencia**.

Onda Sonora: Dominio del Tiempo $x(t)$



1 segundo = 16.000 valores de amplitud.

De la Señal al Espectrograma

De la Señal al Espectrograma

STFT: Short-Time Fourier Transform

De la Señal al Espectrograma

STFT: Short-Time Fourier Transform

- **El principio:** una FFT global pierde el tiempo; importa *qué frecuencias y en qué momento*.

De la Señal al Espectrograma

STFT: Short-Time Fourier Transform

- **El principio:** una FFT global pierde el tiempo; importa *qué frecuencias y en qué momento*.
- **Ventana deslizante:** fragmentos (`frame_length=255`) con solapamiento (`frame_step=128`).

De la Señal al Espectrograma

STFT: Short-Time Fourier Transform

- **El principio:** una FFT global pierde el tiempo; importa *qué frecuencias y en qué momento*.
- **Ventana deslizante:** fragmentos (`frame_length=255`) con solapamiento (`frame_step=128`).
- A cada ventana se le aplica la FFT:

$$X(t, f) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n - t] \cdot e^{-j2\pi f n}$$

De la Señal al Espectrograma

STFT: Short-Time Fourier Transform

- **El principio:** una FFT global pierde el tiempo; importa *qué frecuencias y en qué momento*.
- **Ventana deslizante:** fragmentos (`frame_length=255`) con solapamiento (`frame_step=128`).
- A cada ventana se le aplica la FFT:

$$X(t, f) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n - t] \cdot e^{-j2\pi f n}$$

- **Resultado:** matriz 2D **Tiempo × Frecuencia** = una imagen.

De la Señal al Espectrograma

STFT: Short-Time Fourier Transform

- **El principio:** una FFT global pierde el tiempo; importa *qué frecuencias y en qué momento*.
- **Ventana deslizante:** fragmentos (`frame_length=255`) con solapamiento (`frame_step=128`).
- A cada ventana se le aplica la FFT:


$$X(t, f) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n - t] \cdot e^{-j2\pi f n}$$

- **Resultado:** matriz 2D **Tiempo × Frecuencia** = una imagen.

Espectrograma = Imagen 2D

Lineal

dB (log)



-40 dB 0 dB

La compresión **logarítmica (dB)** revela los formantes débiles: es la representación estándar de entrada a la red.

Tensor: (124, 129, 1) → Alto × Ancho × Canal

04

04

Introducción a la Convolución y Pooling

04

Introducción a la Convolución y Pooling

La necesidad de downscaling e invarianza

El Gran Salto: Visión Convolutacional en Audio

El Gran Salto: Visión Convolutiva en Audio

¿Por qué aplicar convolución 2D a un
espectrograma?

El Gran Salto: Visión Convolutiva en Audio

¿Por qué aplicar convolución 2D a un espectrograma?

- El audio se convirtió en una imagen: tensor $(124, 129, 1)$ (*Tiempo, Frecuencia, Canal*).

El Gran Salto: Visión Convolutiva en Audio

¿Por qué aplicar convolución 2D a un espectrograma?

- **El audio se convirtió en una imagen:** tensor $(124, 129, 1)$ (*Tiempo, Frecuencia, Canal*).
- **Patrones locales:** los fonemas tienen firmas espectrales (formantes, silencios, transitorios).

El Gran Salto: Visión Convolutiva en Audio

¿Por qué aplicar convolución 2D a un espectrograma?

- **El audio se convirtió en una imagen:** tensor $(124, 129, 1)$ (*Tiempo, Frecuencia, Canal*).
- **Patrones locales:** los fonemas tienen firmas espectrales (formantes, silencios, transitorios).
- **Invarianza temporal:** una palabra 100 ms después conserva su forma, solo se desplaza en el eje temporal.

El Gran Salto: Visión Convolutiva en Audio

¿Por qué aplicar convolución 2D a un espectrograma?

- **El audio se convirtió en una imagen:** tensor $(124, 129, 1)$ (*Tiempo, Frecuencia, Canal*).
- **Patrones locales:** los fonemas tienen firmas espectrales (formantes, silencios, transitorios).
- **Invarianza temporal:** una palabra 100 ms después conserva su forma, solo se desplaza en el eje temporal.
- Las capas **Conv2D** extraen esos patrones con **filtros compartidos** (muchos menos parámetros que una red densa).

El Gran Salto: Visión Convolutiva en Audio

¿Por qué aplicar convolución 2D a un espectrograma?

- **El audio se convirtió en una imagen:** tensor $(124, 129, 1)$ (*Tiempo, Frecuencia, Canal*).
- **Patrones locales:** los fonemas tienen firmas espectrales (formantes, silencios, transitorios).
- **Invarianza temporal:** una palabra 100 ms después conserva su forma, solo se desplaza en el eje temporal.
- Las capas `Conv2D` extraen esos patrones con **filtros compartidos** (muchos menos parámetros que una red densa).

Pipeline del Laboratorio: Audio → CNN

1. Audio .WAV (16.000 muestras)

2. STFT → Tensor $(124, 129, 1)$

3. Conv2D + MaxPooling2D

4. GlobalAveragePooling2D

5. Dropout → Dense(3, Softmax)

Capas de Pooling (Submuestreo)

Capas de Pooling (Submuestreo)

Reducción dimensional e invarianzas
espaciales

Capas de Pooling (Submuestreo)

Reducción dimensional e invarianzas espaciales

- **Objetivo:** reducir dimensiones preservando la semántica.

Capas de Pooling (Submuestreo)

Reducción dimensional e invarianzas espaciales

- **Objetivo:** reducir dimensiones preservando la semántica.
- **Fórmula de salida:**

$$O = \left\lfloor \frac{N - f}{s} \right\rfloor + 1$$

Capas de Pooling (Submuestreo)

Reducción dimensional e invarianzas espaciales

- **Objetivo:** reducir dimensiones preservando la semántica.
- **Fórmula de salida:**

$$O = \left\lfloor \frac{N - f}{s} \right\rfloor + 1$$

- N : entrada · f : filtro · s : stride.

Capas de Pooling (Submuestreo)

Reducción dimensional e invarianzas espaciales

- **Objetivo:** reducir dimensiones preservando la semántica.
- **Fórmula de salida:**

$$O = \left\lfloor \frac{N - f}{s} \right\rfloor + 1$$

- N : entrada · f : filtro · s : stride.
- **Beneficios:** menos cómputo y parámetros + **invarianza a traslaciones.**

Capas de Pooling (Submuestreo)

Reducción dimensional e invarianzas espaciales

- **Objetivo:** reducir dimensiones preservando la semántica.
- **Fórmula de salida:**

$$O = \left\lfloor \frac{N - f}{s} \right\rfloor + 1$$

- N : entrada · f : filtro · s : stride.
- **Beneficios:** menos cómputo y parámetros + **invarianza a traslaciones**.



Max Pooling vs. Average Pooling

Max Pooling vs. Average Pooling

Max Pooling

- **Operación:** toma el valor máximo dentro de cada ventana:
 $\max(R)$.
- **Semántica:** "¿apareció la característica buscada en esta región?" (un borde, un formante).
- **Uso:** entre bloques de convolución intermedios para resaltar patrones fuertes.

Prioriza las activaciones dominantes sobre el fondo.

Max Pooling vs. Average Pooling

Max Pooling

- **Operación:** toma el valor máximo dentro de cada ventana: $\max(R)$.
- **Semántica:** "¿apareció la característica buscada en esta región?" (un borde, un formante).
- **Uso:** entre bloques de convolución intermedios para resaltar patrones fuertes.

Prioriza las activaciones dominantes sobre el fondo.



Average Pooling

- **Operación:** promedio aritmético de la región: $(1 / |R|) \cdot \sum x_i$.
- **Semántica:** mide la presencia media o el contexto general del mapa.
- **Uso:** muy común como *Global Average Pooling* antes de la capa final.

Suaviza la señal y retiene información de contexto global.

```
# Paso 1: Carga y extracción del espectrograma (STFT)
wav = load_wav_16k_mono("audio.wav")[:16000]
spectrogram = tf.signal.stft(wav, frame_length=255, frame_step=128)
spectrogram = tf.abs(spectrogram)          # Forma: (124, 129)
X = tf.expand_dims(spectrogram, axis=-1)    # (124, 129, 1)
```

Arquitectura Convolutiva del Laboratorio

```
# Paso 1: Carga y extracción del espectrograma (STFT)
wav = load_wav_16k_mono("audio.wav")[:16000]
spectrogram = tf.signal.stft(wav, frame_length=255, frame_step=128)
spectrogram = tf.abs(spectrogram)          # Forma: (124, 129)
X = tf.expand_dims(spectrogram, axis=-1)    # (124, 129, 1)
```

Arquitectura Convolutiva del Laboratorio


```
# Paso 2: Bloques convolucionales con downscaling progresivo
model = Sequential([
    Input(shape=(124, 129, 1)),
    Conv2D(16, 3, activation="relu", padding="same"),
    MaxPooling2D(pool_size=2),                    # 62 x 64
    Conv2D(32, 3, activation="relu", padding="same"),
    MaxPooling2D(pool_size=2),                    # 31 x 32
    Conv2D(64, 3, activation="relu", padding="same"),
    GlobalAveragePooling2D(),                     # 64 características
    Dropout(0.3),
    Dense(3, activation="softmax")                # 3 clases
])
```

Arquitectura Convolutiva del Laboratorio


```
# Paso 3: Regularización, compilación y callbacks
model.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=0.001, clipnorm=1.0),
    loss="categorical_crossentropy",
    metrics=["accuracy"]
)

early = tf.keras.callbacks.EarlyStopping(
    monitor="val_loss", patience=8, restore_best_weights=True
)

history = model.fit(
    X_train, Y_train,
    validation_data=(X_val, Y_val),
    epochs=50, batch_size=16, callbacks=[early]
)
```




Laboratorio Práctico de la Sesión 3





Laboratorio Práctico de la Sesión 3

Clasificación Acústica Multiclase con Espectrogramas y CNN





Laboratorio Práctico de la Sesión 3

Clasificación Acústica Multiclase con Espectrogramas y CNN

1

Pipeline STFT y visualización 2D/3D

Conversión de archivos .WAV a tensores espectrales en decibelios.



Laboratorio Práctico de la Sesión 3

Clasificación Acústica Multiclase con Espectrogramas y CNN

1

Pipeline STFT y visualización 2D/3D

Conversión de archivos .WAV a tensores espectrales en decibelios.

2

Entrenamiento de la CNN (Conv2D + Pooling)

Extracción jerárquica de características acústicas invariantes.



Laboratorio Práctico de la Sesión 3

Clasificación Acústica Multiclase con Espectrogramas y CNN

1

Pipeline STFT y visualización 2D/3D

Conversión de archivos .WAV a tensores espectrales en decibelios.

2

Entrenamiento de la CNN (Conv2D + Pooling)

Extracción jerárquica de características acústicas invariantes.

3

Evaluación clínica: matriz de confusión y F1-Score

Diagnóstico de aciertos, falsos positivos y balance por clase.

Lo que aprendimos hoy

Lo que aprendimos hoy

Diagnóstico

Leer las curvas de pérdida y reconocer overfitting, underfitting y patologías del gradiente.

Lo que aprendimos hoy

Diagnóstico

Leer las curvas de pérdida y reconocer overfitting, underfitting y patologías del gradiente.

Regularización

Dropout, Early Stopping y Gradient Clipping como herramientas de estabilización.

Lo que aprendimos hoy

Diagnóstico

Leer las curvas de pérdida y reconocer overfitting, underfitting y patologías del gradiente.

Regularización

Dropout, Early Stopping y Gradient Clipping como herramientas de estabilización.

Señales

La STFT convierte una señal 1D en un espectrograma 2D: tiempo $\times$ frecuencia.

Lo que aprendimos hoy

Diagnóstico

Leer las curvas de pérdida y reconocer overfitting, underfitting y patologías del gradiente.

Regularización

Dropout, Early Stopping y Gradient Clipping como herramientas de estabilización.

Señales

La STFT convierte una señal 1D en un espectrograma 2D: tiempo $\times$ frecuencia.

Convolución

Conv2D y Pooling explotan la estructura espacial con invarianza a traslaciones.

Lo que aprendimos hoy

Diagnóstico

Leer las curvas de pérdida y reconocer overfitting, underfitting y patologías del gradiente.

Regularización

Dropout, Early Stopping y Gradient Clipping como herramientas de estabilización.

Señales

La STFT convierte una señal 1D en un espectrograma 2D: tiempo $\times$ frecuencia.

Convolución

Conv2D y Pooling explotan la estructura espacial con invarianza a traslaciones.

DEEP LEARNING · Pontificia Universidad Javeriana Cali
Jan Polanco Velasco