



Modelos Auto Regresivos


Jan Polanco Velasco

Modelos Auto Regresivos

- ◊ Antes de hablar de DL o RNN hablemos sobre los componentes.
- ◊ Libro recomendado: "Deep learning with python" del autor Francois Chollet.
- ◊ Pregunta: ¿Cuales pueden ser esas aplicaciones que puede resolver el DL?

Modelos Auto Regresivos


- ◈ Regresión Lineal
- ◈ Función de costo
- ◈ Gradiente descendente
- ◈ Regresión Lineal multivariada
- ◈ Regresión Logística.



Modelos Auto Regresivos

- ◊ Regresión Lineal
- ◊ Relación lineal
- ◊ Este modelo describe una **relación lineal** entre las entradas x y las salidas y .
- ◊ donde w_0 y w_1 representan el intercepto y la pendiente de la recta, respectivamente.


$$y = w_0 + w_1 \cdot x,$$



Modelos Auto Regresivos

- ◇ Regresión Lineal
- ◇ Relación lineal
- ◇ Este modelo describe una **relación lineal** entre las entradas x y las salidas y .
- ◇ donde w_0 y w_1 (weights) representan el intercepto y la pendiente de la recta, respectivamente.


$$y = w_0 + w_1 \cdot x,$$



Modelos Auto Regresivos

- ◊ Función de costos
- ◊ Los pesos pueden tomar cualquier valor
- ◊ Diferentes pesos producen diferentes rectas.
- ◊ Es necesario calcular la función de costo (Los mejores pesos)


$$y = w_0 + w_1 \cdot x,$$



Modelos Auto Regresivos

- ◊ Función de costos
- ◊ Los pesos pueden tomar cualquier valor
- ◊ Diferentes pesos producen diferentes rectas.
- ◊ Es necesario calcular la función de costo (Los mejores pesos)
- ◊ La función de costo, asumir w_0 conocido

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$



Modelos Auto Regresivos

10 Most Common Loss Functions in Machine Learning

Loss Function Name	Description	Function
--------------------	-------------	----------

Regression Loss Functions

Mean Bias Error	Captures average bias in prediction. But is rarely used for training.	$\mathcal{L}_{MBE} = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))$
Mean Absolute Error	Measures absolute average bias in prediction. Also called L1 Loss.	$\mathcal{L}_{MAE} = \frac{1}{N} \sum_{i=1}^N y_i - f(x_i) $
Mean Squared Error	Average squared distance between actual and predicted. Also called L2 Loss.	$\mathcal{L}_{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2$
Root Mean Squared Error	Square root of MSE. Loss and dependent variable have same units.	$\mathcal{L}_{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2}$
Huber Loss	A combination of MSE and MAE. It is parametric loss function.	$\mathcal{L}_{Huberloss} = \begin{cases} \frac{1}{2}(y_i - f(x_i))^2 & : y_i - f(x_i) \leq \delta \\ \delta(y_i - f(x_i) - \frac{1}{2}\delta) & : otherwise \end{cases}$
Log Cosh Loss	Similar to Huber Loss + non-parametric. But computationally expensive.	$\mathcal{L}_{LogCosh} = \frac{1}{N} \sum_{i=1}^N \log(\cosh(f(x_i) - y_i))$

Classification Loss Functions (Binary + Multi-class)


Binary Cross Entropy (BCE)	Loss function for binary classification tasks.	$\mathcal{L}_{BCE} = \frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(x_i)) + (1 - y_i) \cdot \log(1 - p(x_i))$
Hinge Loss	Penalizes wrong and right (but less confident) predictions. Commonly used in SVMs.	$\mathcal{L}_{Hinge} = \max(0, 1 - (f(x) \cdot y))$
Cross Entropy Loss	Extension of BCE loss to multi-class classification.	$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^M y_{ij} \cdot \log(f(x_{ij}))$ N : samples; M : classes
KL Divergence	Minimizes the divergence between predicted and true probability distribution	$\mathcal{L}_{KL} = \sum_{i=1}^N y_i \cdot \log\left(\frac{y_i}{f(x_i)}\right)$

Modelos Auto Regresivos

- ◆ Gradiente Descendiente.

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$\underbrace{w^{(t+1)}}_{\text{position of next iteration}} = \underbrace{w}_{\text{position of previous step}} - \underbrace{\alpha}_{\text{learning rate}} \underbrace{\nabla f_i(w^{(t)})}_{\text{observation } i}$$




Modelos Auto Regresivos

- ◆ Gradiente Descendiente.

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$\underbrace{w^{(t+1)}}_{\text{position of next iteration}} = \underbrace{w}_{\text{position of previous step}} - \underbrace{\alpha}_{\text{learning rate}} \underbrace{\nabla f_i(w^{(t)})}_{\text{observation } i}$$




Modelos Auto Regresivos

- ◆ Gradiente Descendiente.

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$\underbrace{w^{(t+1)}}_{\text{position of next iteration}} = \underbrace{w}_{\text{position of previous step}} - \underbrace{\alpha}_{\text{learning rate}} \underbrace{\nabla f_i(w^{(t)})}_{\text{observation } i}$$





Modelos Auto Regresivos

- ◆ Gradiente Descendiente.

$$\mathcal{L}(w_1) = \sum_{i=1}^N (w_1 \cdot x_i - y_i)^2$$

$$\underbrace{w^{(t+1)}}_{\text{position of next iteration}} = \underbrace{w}_{\text{position of previous step}} - \underbrace{\alpha}_{\text{learning rate}} \underbrace{\nabla f_i(w^{(t)})}_{\text{observation } i}$$

Gradient Descent




Datamapu

Modelos Auto Regresivos

- ◆ Regresión lineal multivariada
- ◆ Se puede aplicar a datos con múltiples atributos.
- ◆ Los **parámetros** del modelo se estiman a partir de los conceptos de **Función de costo** y **gradiente descendente** .


$$\hat{y} = w_0 + \sum_{j=1}^m w_j \cdot x_j$$



Modelos Auto Regresivos

- ◆ Regresión lineal multivariada.
- ◆ En este caso, la predicción se calcula como una **combinación lineal de todos los atributos de entrada**.

$$\hat{y} = w_0 + \sum_{j=1}^m w_j \cdot x_j$$




Modelos Auto Regresivos

- ◈ Regresión logística.
- ◈ Realiza predicciones a partir de una combinación lineal.
- ◈ Se mide la probabilidad de que una instancia pertenezca a una de las dos clases (clasificación binaria)

Donde:

- $\hat{y}$ es la probabilidad de que $y = 1$ dado el vector de atributos $\mathbf{x}$.
- $\sigma(\cdot)$ es la función sigmoide.


$$\hat{y} = p(y = 1|\mathbf{x}) = \sigma \left(w_0 + \sum_{j=1}^m w_j x_j \right)$$



Modelos Auto Regresivos

- ◊ Regresión logística.
- ◊ La combinación lineal toma cualquier valor real.
- ◊ Probabilidad a la predicción, se usa la función sigmoideal

$$\hat{y} = p(y = 1|\mathbf{x}) = \sigma \left(w_0 + \sum_{j=1}^m w_j x_j \right)$$





Donde:

- $\hat{y}$ es la probabilidad de que $y = 1$ dado el vector de atributos $\mathbf{x}$.
- $\sigma(\cdot)$ es la función sigmoide.


Modelos Auto Regresivos

- ◆ Red Neuronal Fully Connected
- ◆ Capa de Entrada (input Layer)
- ◆ Capa oculta (hidden Layer -h)
- ◆ Capa de salida (Output Layer)
- ◆ ¿Cuántas capas tiene la NN?



Modelos Auto Regresivos

- ◆ Red Neuronal Fully Connected
- ◆ La capa de entrada no suele considerarse
- ◆ Tiene 4 capas. $L=4$




Modelos Auto Regresivos

- ◊ El superíndice indica la capa.
- ◊ h_1 necesita 3+1 parámetros
- ◊ La primera capa oculta necesita 4 x 5 parámetros


Ecuación General para h_1 :

$$h_1 = g \left(w_{1,0}^{[1]} + \sum_{j=1}^3 w_{1,j}^{[1]} x_j \right)$$

- $g(\cdot)$: Función de activación, que puede ser ReLU, sigmoide, entre otras.
- $w_{1,0}^{[1]}$: Bias o término de sesgo.
- $w_{1,j}^{[1]}$: Peso asociado a cada entrada x_j .



Modelos Auto Regresivos




x_1

x_2

x_3

Modelos Auto Regresivos



x_1

x_2

x_3

Modelos Auto Regresivos

- ◆ Función de Activación
- ◆ **Añaden No Linealidad:** Las funciones de activación son esenciales para agregar un componente no lineal en las redes neuronales, permitiendo que estas redes puedan aprender y modelar relaciones complejas en los datos.
- ◆ **Modelo Lineal sin Activación:** Sin funciones de activación, una red neuronal se reduce a un modelo lineal, sin importar cuántas capas ocultas contenga.
- ◆ **En Cualquier Capa:** Las funciones de activación pueden colocarse en cualquier capa de la red.

Modelos Auto Regresivos

- ◆ Ciertas funciones son más apropiadas para capas de salida.
- ◆ Otras son mejores para capas ocultas, optimizando el rendimiento de la red.


Definición Matemática

Para una unidad en una capa oculta o de salida, el cálculo del valor se realiza mediante la función de activación $g(\cdot)$:

$$h_2 = g \left(w_{2,0}^{[1]} + \sum_{j=1}^4 w_{2,j}^{[1]} x_j \right)$$


Modelos Auto Regresivos

- ◆ Tipos de Funciones de Activación.
- ◆ Función identidad
- ◆ Salida igual a entrada
- ◆ Recomendación diapo anterior (modelo lineal y no tiene sentido)
- ◆ Se puede usar para regresión.




Modelos Auto Regresivos

- ◆ Tipos de Funciones de Activación.
- ◆ Función sigmoide
- ◆ Valores $[0,1]$
- ◆ Se usaba al inicio de la NN pero tiene latencia.
- ◆ Softmax es la versión generalizada para clasificación en capa de salida.




Modelos Auto Regresivos

- ◆ Tipos de Funciones de Activación.
- ◆ Función Tangente Hiperbólica
- ◆ .Valores $[-1,1]$
- ◆ Normalizar los valores de la entrada.
- ◆ Puede tener problemas de gradientes que se desvanecen.(vanishing gradient problem).











Modelos Auto Regresivos

- ◊ Tipos de Funciones de Activación.
- ◊ Función ReLu (Rectified Linear Unit)
- ◊ Es muy usada
- ◊ Se suele usar en capas ocultas.
- ◊ Hay otros tipos de funciones de activación?




Neural Network Activation Functions: a small subset!

ReLU  $\max(0, x)$	GELU  $\frac{x}{2} \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (x + ax^3) \right) \right)$	PReLU  $\max(0, x)$
ELU  $\begin{cases} x & \text{if } x > 0 \\ \alpha(x \exp x - 1) & \text{if } x < 0 \end{cases}$	Swish  $\frac{x}{1 + \exp -x}$	SELU  $\alpha(\max(0, x) + \min(0, \beta(\exp x - 1)))$
SoftPlus  $\frac{1}{\beta} \log(1 + \exp(\beta x))$	Mish  $x \tanh \left(\frac{1}{\beta} \log(1 + \exp(\beta x)) \right)$	RReLU  $\begin{cases} x & \text{if } x \geq 0 \\ ax & \text{if } x < 0 \text{ with } a \sim \mathcal{R}(l, u) \end{cases}$
HardSwish  $\begin{cases} 0 & \text{if } x \leq -3 \\ x & \text{if } x \geq 3 \\ x(x+3)/6 & \text{otherwise} \end{cases}$	Sigmoid  $\frac{1}{1 + \exp(-x)}$	SoftSign  $\frac{x}{1 + x }$
Tanh  $\tanh(x)$	Hard tanh  $\begin{cases} a & \text{if } x \geq a \\ b & \text{if } x \leq b \\ x & \text{otherwise} \end{cases}$	Hard Sigmoid  $\begin{cases} 0 & \text{if } x \leq -3 \\ 1 & \text{if } x \geq 3 \\ x/6 + 1/2 & \text{otherwise} \end{cases}$
Tanh Shrink  $x - \tanh(x)$	Soft Shrink  $\begin{cases} x - \lambda & \text{if } x > \lambda \\ x + \lambda & \text{if } x < -\lambda \\ 0 & \text{otherwise} \end{cases}$	Hard Shrink  $\begin{cases} x & \text{if } x > \lambda \\ x & \text{if } x < -\lambda \\ 0 & \text{otherwise} \end{cases}$


Modelos Auto Regresivos

- ◊ Estimación de Hiper parámetros.
- ◊ Parámetros son los pesos “w”
- ◊ Los hiper parámetros son los valores que afectan los parámetros.
- ◊ Cantidad de capas, LR (step size de GD)
- ◊ Ser cuidadosos con la elección de la función de costo.




Modelos Auto Regresivos

- ◈ En regresión se suele usar RMSE.
- ◈ En Clasificación Binaria se suele usar entropía cruzada binaria.
- ◈ Multiclase: Entropía cruzada categórica.
- ◈ Solver: GD, ADAM, etc




Modelos Auto Regresivos

- ♦ Hiper parámetros:
- ♦ L cantidad capas o profundidad de la red.
- ♦ Número de unidades por capa. Entrada y salida depende del problema.
- ♦ Estructura fija (Rectangular)
- ♦ Estructura variable (Piramidal)



Modelos Auto Regresivos

- ◊ Hiper parámetros:
- ◊ LR Learning Rate.
- ◊ Funciones de Activación.
- ◊ Batch size
- ◊ Epochs
- ◊ Procesos de regularización.
- ◊ Trial and Error
- ◊ Train/Validation/Test
- ◊ 60/20/20 pocos datos
- ◊ 90/5/5 muchos datos
- ◊ Grid/Random/Bayesian Search



Modelos Auto Regresivos

- ◊ Juguemos un rato con una NN

Modelos Auto Regresivos

- ◊ Datos secuenciales.
- ◊ Qué son los datos secuenciales?



Modelos Auto Regresivos

- ◊ Datos secuenciales.
- ◊ Qué son los datos secuenciales?
- ◊ El dato actual depende de la información anterior.
- ◊ Dependencia temporal



Modelos Auto Regresivos

- ◊ Datos secuenciales.
- ◊ Qué son los datos secuenciales?
- ◊ Series de tiempo
- ◊ Señales de sensores
- ◊ La voz (audio)
- ◊ Secuencia de genes (gene sequences).
- ◊ Información climática.



Modelos Auto Regresivos

- ◊ Datos secuenciales.
- ◊ Una NN asume que los datos no son secuenciales y que cada punto de datos es independiente de otros puntos de datos.
- ◊ Limitación
- ◊ Ejemplo Temperatura – Humedad
- ◊ Carecen de memoria
- ◊ Sufren de Gradientes que se desvanecen con secuencias largas.

